

CAT

Machine-Learning-Projektarbeit

World Cup 2026 Prediction

Praktischer Analysebericht mit Python, Data Science und Modellbewertung

Python

Pandas

Scikit-learn

Regression

Classification

Streamlit

Teilnehmerin: Mahdiah Sadat Esmaeili

Dateiname: Esmaeili_Mahdiah_Sadat__ML__CAT__06_2026.pdf

1. Projektziel

Ziel des Projekts ist es, historische Fußballdaten zu verwenden, um Spiele der FIFA-Weltmeisterschaft 2026 modellbasiert zu analysieren und vorherzusagen. Dabei werden zwei Aufgaben kombiniert:

- **Regression:** Vorhersage der erwarteten Tore beider Teams.
- **Klassifikation:** Vorhersage des Spielergebnisses als Sieg Team A, Unentschieden oder Sieg Team B.

Zusätzlich werden die Ergebnisse in einem Streamlit-Dashboard präsentiert, sodass Datenanalyse, Modellvergleich und Simulation interaktiv nachvollziehbar sind.

2. Datenbasis und Vorbereitung

Die Datenbasis besteht aus historischen internationalen Fußballspielen, den geplanten WM-2026-Spielen und einer zusätzlichen Datei für bereits gespielte aktuelle Matches. Die historischen Daten wurden gefiltert und für die 48 relevanten WM-Teams ab 1995 vorbereitet.

Raw Data


all_matches.csv, countries_names.csv,
FIFA2026_schedule.csv und
FIFA2026_schedule_Fixtures.csv

Processed Data


clean_all_matches.csv, model_dataset.csv,
wc2026_fixtures.csv,
wc2026_fixture_features.csv

3. Explorative Datenanalyse

Die EDA dient dazu, die Struktur der Daten zu verstehen. Untersucht wurden u.a. Ergebnisverteilung, Anzahl der Spiele pro Jahr, durchschnittliche Tore pro Jahr und häufig vorkommende Teams bzw. Turniere.



eda_result_distribution.png



eda_avg_goals_per_year.png

4. Feature Engineering

Aus den Rohdaten wurden modellierbare Merkmale erzeugt. Dazu gehören historische Leistungswerte, Tordurchschnitte, Heim-/Auswärtsinformationen, Teamstärkeindikatoren und vorbereitete Match-Features für die WM-2026-Fixtures.

- Bereinigung und Standardisierung von Teamnamen
- Filterung auf relevante WM-2026-Teams
- Berechnung historischer Team- und Match-Features
- Erstellung eines finalen Modelldatensatzes für Training und Test

5. Modellierung: Regression für Tore

Für die Vorhersage der Tore wurden mehrere Regressionsmodelle verglichen. Wichtige Bewertungsmetriken sind MAE, RMSE und R^2 . Der MAE ist besonders anschaulich, weil er den durchschnittlichen Fehler in Toren beschreibt.


Model	Mean MAE	Mean RMSE	Mean R^2	Outcome Accuracy from rounded score
Gradient Boosting Regressor	0.913	1.195	0.258	0.624
Ridge Regression	0.913	1.207	0.242	0.613
XGBoost Regressor	0.914	1.195	0.258	0.618
Random Forest Regressor	0.917	1.202	0.249	0.627
LightGBM Regressor	0.923	1.219	0.229	0.629
Poisson Regression	0.925	1.231	0.217	0.624
Dummy Mean Baseline	1.036	1.389	-0.003	0.582

Die besten Modelle liegen beim durchschnittlichen Torfehler ungefähr bei 0,91 Toren. Das ist für Fußball realistisch, weil Ergebnisse stark von nicht vollständig beobachtbaren Faktoren wie Tagesform, Verletzungen, Karten oder taktischen Entscheidungen beeinflusst werden.

6. Modellierung: Klassifikation für Spielergebnisse

Das Endergebnis wurde zusätzlich als Klassifikationsproblem formuliert. Die Zielklassen sind: Sieg von Team A, Unentschieden und Sieg von Team B.

Model	Accuracy	Weighted F1
Logistic Regression	0.624	0.622
Random Forest Classifier	0.641	0.614
Dummy Majority Baseline	0.582	0.428




classification_model_comparison.png

Random Forest erreicht die höchste Accuracy, während Logistic Regression einen ausgewogenen Weighted-F1-Wert zeigt. Beide Modelle liegen über der Dummy Majority Baseline, wodurch sichtbar wird, dass aus den Daten tatsächlich Muster gelernt wurden.

7. Interpretierbarkeit: Feature Importance


Die Feature-Importance-Analyse zeigt, welche Merkmale besonders stark zur Modellentscheidung beitragen. Dadurch wird das Modell nicht nur als Black Box betrachtet, sondern inhaltlich interpretierbarer.



rf_feature_importance_top20.png

8. Vorhersage der WM 2026

Auf Basis der trainierten Modelle wurden die Gruppenspiele der WM 2026 simuliert. Aus den vorhergesagten Toren wurden Punkte, Tordifferenz und Gruppenplatzierungen abgeleitet. Anschließend wurde eine erste Knockout-Simulation erstellt.



wc2026_expected_goals_by_group.png

Wichtig: Die Ergebnisse sind modellbasierte Simulationen und keine sicheren Prognosen.

9. Validierung mit aktuellen Spielen

Zur zusätzlichen Prüfung wurden bereits gespielte WM-2026-Matches in einer Live-Datei ergänzt und mit Modellvorhersagen verglichen.

Model	Outcome Accuracy	Exact Score Accuracy	Mean Team Goal MAE	Total Goals MAE
Dummy Mean Baseline	0.583	0.083	0.879	1.611
Poisson Regression	0.583	0.083	1.161	1.947
Ridge Regression	0.583	0.083	1.309	2.141
Gradient Boosting Regressor	0.583	0.083	1.310	2.170
XGBoost Regressor	0.583	0.083	1.358	2.208
LightGBM Regressor	0.583	0.083	1.381	2.277
Random Forest Regressor	0.500	0.000	1.357	2.382

Hinweis zur Tabelle: In der exportierten Validierungsdatei steht `completed_matches = 0`, obwohl in der Detailtabelle 12 tatsächliche Match-Zeilen vorhanden sind. Das wird als Reporting-Bug im Export interpretiert, nicht als inhaltlicher Fehler der Modellbewertung.

10. Streamlit-Dashboard

Das Projekt wurde zusätzlich als interaktives Streamlit-Dashboard umgesetzt. Dort können Datenanalyse, Modellvergleich, WM-2026-Vorhersage, Live-Simulation und Ergebnisarchiv präsentiert werden.

- EDA und Visualisierungen
- PCA / t-SNE / UMAP / Clustering
- Regression und Klassifikation
- WM-2026-Gruppen- und K.O.-Simulation
- Live-Simulator für ausgewählte Teams

11. Fazit

Das Projekt zeigt einen vollständigen Machine-Learning-Workflow: von der Datenaufbereitung über Feature Engineering und Modellvergleich bis zur interaktiven Präsentation. Die Modelle übertreffen einfache Baselines, allerdings bleibt Fußball aufgrund vieler nicht beobachtbarer Einflussfaktoren schwer exakt vorhersagbar. Die Stärke des Projekts liegt daher nicht in einer sicheren Prognose, sondern in einer nachvollziehbaren datengetriebenen Simulation.