

Machine-Learning-Projektarbeit

World Cup 2026 Prediction

Dokumentation der Arbeitsschritte, Dateien, Notebooks und Reproduzierbarkeit

[Project Structure](#)[Data Flow](#)[Notebooks](#)[Outputs](#)[Reproducibility](#)

Teilnehmerin: Mahdiah Sadat Esmaeili

Dateiname: Esmaeili_Mahdiah_Sadat__ML__NvS__06_2026.pdf

1. Projektstruktur

Das Projekt ist in Daten, Notebooks, Outputs und Streamlit-App aufgeteilt. Dadurch sind Analyse, Modellierung und Präsentation sauber getrennt.

```
ML_Abschlussprojekt_WorldCup2026/
├── app/
│   ├── streamlit_app.py
│   ├── translations.py
│   └── soccer_bg.png
├── data/
│   ├── raw/
│   │   ├── all_matches.csv
│   │   ├── countries_names.csv
│   │   ├── FIFA2026_schedule.csv
│   │   ├── FIFA2026_schedule_Fixtures.csv
│   │   └── live_new_matches.csv
│   └── processed/
│       ├── clean_all_matches.csv
│       ├── model_dataset.csv
│       ├── wc2026_fixtures.csv
│       ├── wc2026_fixture_features.csv
│       └── model_dataset_live.csv
├── notebooks/
│   └── 01 ... 08 Jupyter Notebooks
└── output/
    ├── figures/
    ├── tables/
    ├── actual_worldcup2026_validation/
    └── regression_model_comparison_presentation/
```

2. Datenfluss

1. **Raw Data:** Historische Spiele und WM-2026-Spielplan werden eingelesen.
2. **Cleaning:** Teamnamen, Datumsfelder, Scores und relevante Turniere werden standardisiert.
3. **Filtering:** Die Daten werden auf Spiele ab 1995 und die 48 WM-2026-Teams fokussiert.
4. **Feature Engineering:** Historische Team- und Match-Features werden berechnet.
5. **Model Dataset:** Der finale Trainingsdatensatz wird erstellt.
6. **Training and Evaluation:** Regression und Klassifikation werden trainiert und bewertet.
7. **Prediction:** WM-2026-Fixtures werden mit den Modellen vorhergesagt.
8. **Dashboard:** Ergebnisse werden in Streamlit visualisiert.

3. Notebook-Übersicht

Notebook	Purpose
01_data_understanding_and_preprocessing.ipynb	Data understanding, filtering, cleaning, EDA and baseline preparation
02_feature_engineering_filtered_48_teams.ipynb	Feature engineering for the 48 World Cup teams from historical matches
03_model_training_presentation_ready_fixed_v2.ipynb	Training and evaluation of goal regression and outcome classification models
04_worldcup2026_group_prediction_fixed_group_stage.ipynb	Prediction of group-stage matches and group tables
05_round_of_32_prediction_v2.ipynb	Simulation of Round of 32 based on predicted group rankings
06_goal_regression_model_comparison_presentation.ipynb	Regression model comparison for expected goals
06_goal_regression_model_comparison_presentation_per_model_plots_extended.ipynb	Extended per-model plots for presentation
06_goal_regression_model_comparison_presentation_per_model_plots_interactive_hover.ipynb	Interactive hover plots for team/model interpretation
06_goal_regression_model_comparison_presentation_per_model_plots_interactive_hover_fixed.ipynb	Corrected interactive model-visualization notebook
07_actual_worldcup2026_model_validation_fixed_v3.ipynb	Validation on actual completed World Cup 2026 matches
08_final_presentation_dashboard_v2.ipynb	Final dashboard preparation and presentation assets

4. Reproduzierbarer Ablauf

Um die Ergebnisse erneut zu erzeugen, sollte die Ausführung in der Reihenfolge der Notebooks erfolgen. Die Nummerierung der Notebooks bildet den Workflow ab.

1. Notebook 01 ausführen: Datenverständnis, Cleaning und erste EDA.
2. Notebook 02 ausführen: Feature Engineering für die 48 WM-Teams.
3. Notebook 03 ausführen: Modelltraining und erste Bewertung.
4. Notebook 04 ausführen: Gruppenspiel-Vorhersage.
5. Notebook 05 ausführen: Round-of-32-Simulation.

6. Notebook 06-Varianten ausführen: Erweiterte Regression- und Visualisierungsanalyse.
7. Notebook 07 ausführen: Validierung mit tatsächlichen WM-2026-Spielen.
8. Notebook 08 bzw. Streamlit-App verwenden: Präsentation und Dashboard.

5. Wichtige Output-Dateien

Output-Bereich	Beispiele	Bedeutung
output/figures	classification_model_comparison.png, rf_feature_importance_top20.png	Statische Abbildungen für Bericht und Präsentation
output/tables	classification_model_metrics.csv, goal_regression_model_metrics.csv	Tabellarische Modellmetriken
actual_worldcup2026_validation	actual_vs_predicted_completed_matches_all_models.csv	Vergleich von echten Ergebnissen und Modellvorhersagen
regression_model_comparison_presentation	per-model plots, comparison tables	Erweiterte Präsentationsgrafiken und Modellvergleich

6. Ausführung der Streamlit-App

Die Streamlit-App befindet sich im Ordner **app**. Sie kann lokal gestartet werden, wenn die Python-Umgebung und die benötigten Pakete installiert sind.

```
cd app
streamlit run streamlit_app.py
```

Die App greift auf vorbereitete Tabellen und Grafiken aus den Ordnern data und output zu. Dadurch müssen Ergebnisse nicht live im Dashboard neu berechnet werden, sondern können stabil präsentiert werden.

7. Nachvollziehbarkeit der Ergebnisse

Die Nachvollziehbarkeit entsteht durch die klare Trennung der Schritte: Raw Data, Processed Data, Notebooks, Tables, Figures und Dashboard. Jede zentrale Entscheidung im Workflow ist entweder in einem Notebook, einer Tabelle oder einer Abbildung dokumentiert.

- Die Rohdaten bleiben separat erhalten.
- Verarbeitete Daten werden als CSV gespeichert.
- Modellmetriken werden exportiert.
- Abbildungen werden für Bericht und Präsentation gespeichert.
- Das Dashboard nutzt diese Ergebnisse als präsentierbare Oberfläche.

8. Qualitäts- und Plausibilitätskontrolle

Die Modellqualität wurde nicht nur anhand einzelner Scores beurteilt, sondern anhand mehrerer Perspektiven: Regressionmetriken, Klassifikationsmetriken, Baseline-Vergleich, Feature Importance und Validierung mit aktuellen Ergebnissen.

Dokumentierter Hinweis: In der aktuellen Validierungstabelle gibt es ein kleines Reporting-Problem: `completed_matches` wird als 0 exportiert, obwohl die Detailtabelle tatsächliche Matches enthält. Für die Interpretation wurde deshalb zusätzlich die Detailtabelle geprüft.

9. Fazit zu NvS

Dieses NvS-Dokument zeigt den nachvollziehbaren Arbeitsprozess des Projekts. Es macht sichtbar, welche Dateien verwendet wurden, wie Daten verarbeitet wurden, in welcher Reihenfolge die Notebooks laufen und wie die Ergebnisse reproduziert oder im Streamlit-Dashboard präsentiert werden können.